

1 基于 Informer 与 LSTM 的雅砻江梯级水电站短期出力预测对比研究

作者：王钰贤（四川大学水利水电学院，水利科学与工程专业，2025 级）

通讯说明：本文为方法预演稿；数据为计算机合成拟真序列，非现场 SCADA。

1.1 摘要

针对梯级水电站日前至小时级出力预测对长时序依赖建模的需求，本文在雅砻江流域合成多源数据集上，以两河口站为对象，构建输入序列 168 h、预测视界 24 h 的短期出力预测任务，对比传统双层 LSTM 基线与 Informer 编码器—解码器模型的性能。两种模型均采用气象要素与历史出力共 6 维输入，按时间顺序 70%/15%/15% 划分训练、验证与测试集。测试结果表明：LSTM 的 MAE 为 30.36 MW、RMSE 为 39.09 MW、MAPE 为 10.44%；Informer 的 MAE 为 30.49 MW、RMSE 为 39.15 MW、MAPE 为 10.20%。在本预演设定下，LSTM 在点预测误差意义上略优，Informer 在平均百分比误差上略低；二者差异小于 0.5%，提示在平滑合成数据上模型选择需结合超参搜索、概率预测与现场数据再验证。本文给出了可复现的代码、Nature 风格对比图及向真实安康/雅砻江数据迁移的路径，可为后续大创与论文工作提供基线框架。

关键词：雅砻江；水电出力预测；Informer；LSTM；长序列预测；深度学习

1.2 1 引言

1.2.1 1.1 问题背景与尺度

我国流域级水风光互补基地正在由规划走向规模化运行：梯级水电承担调节与基荷，风光出力波动显著，调度侧需要小时至日前尺度的可用功率预见以安排备用、泄放与新能源消纳 [4,9]。雅砻江流域是典型的高海拔、季风水文驱动走廊，气象—径流—库水位—机组出力之间存在明显时滞与季节分异；在这一背景下，短期出力预测不再是单点曲线拟合，而是服务于多能协同的运行决策接口 [4,6]。

从任务定义看，本文关注单站（两河口）未来 24 h 有功出力的多步预测：输入为过去 168 h 的气象与历史出力，输出为未来 24 h 出力轨迹。该设定对应日前滚动修正与日内计划衔接的常见工程需求，也与长序列时间序列预测（long sequence time-series forecasting, LSTF）问题在形式上对齐 [1]。

1.2.2 1.2 技术脉络与未解问题

深度学习为非线性时序建模提供了统一框架 [11]；LSTM 通过门控记忆单元缓解梯度消失，长期作为水电出力、径流与负荷预测的强基线 [2,7,8,10]。面向更长输入窗口，Transformer 类模型以注意力机制聚合全序列信息；Informer 进一步提出 ProbSparse 注意力、蒸馏编码与生成式解码，以改善 LSTF 的计算与信息瓶颈 [1]。同期工作还将 Transformer 与 LSTM、注意力模块组合用于省域水电发电量预测，报告了相对单一 LSTM 的精度提升 [8]；水文领域综述则指出，混合式深度模型与输入/超参优化策略对径流类预测效果影响显著，不宜默认某一种网络结构普适最优 [5,6]。

然而，面向梯级水电站短期出力的对比研究仍存在三点空白：（1）多数工作报告单一模型精度，缺少在同一数据管道、同一划分、同一评价协议下对「编码器—解码器 Transformer 变体」与「直接多步 LSTM」的并排检验；（2）水电场景常混入分解—重构、多站联合等复杂模块，难以分离架构本身带来的增益；（3）公开可复现的、带流域机理特征的长时序样本不足，学生与工程预演难以在接触现场 SCADA 之前建立可审计的基线。

1.2.3 1.3 本文工作与创新点（边界明确）

本文在雅砻江流域程序合成的拟真小时数据上（非现场实测），构建可复现对比实验，不声称已解决真实电厂预测问题，而是验证方法链路与模型排序是否可信。主要贡献如下：

1. **统一基准协议**：固定 $L_{enc} = 168$ h、 $L_{pred} = 24$ h、6 维输入与时间顺序 70%/15%/15% 划分，给出 LSTM 与 Informer 的可对比实现与开源脚本。
2. **结构对照**：LSTM 采用「序列编码 + 末状态直接多步回归」；Informer 采用「编码器—解码器 + 标签段已知」的 LSTF 范式 [1]，参数量约 0.21 M 与 0.18 M，训练均在同一 GPU 环境完成。
3. **分层评价**：除 MAE/RMSE/MAPE 外，给出分提前步长 MAE 与误差分布（Fig2-Fig3），避免仅用单标量掩盖远期步长退化。
4. **可迁移讨论**：基于实测指标（表 1）讨论合成数据上 LSTM 在 MAE/RMSE 略优、Informer 在 MAPE 略优的含义，并列接入安康/雅砻江脱敏数据后的验证路线。

创新点表述（投稿用，宜保持克制）：提出一套面向梯级水电短期出力的 Informer—LSTM 对照实验框架与可复现基线；在合成数据上首次（本文范围内）给出两种架构在相同视界下的并排误差与分步长诊断。该创新属于方法与实验设计层面，仍需真实数据与外推检验后方可上升为工程结论。

1.3 2 数据与问题定义

1.3.1 2.1 数据来源与说明

训练数据来自雅砻江流域水风光互补系统模拟数据集（2020-01-01 至 2024-12-31，1 h 分辨率），包含 3 座梯级水电站、光伏与风电场及区域气象字段。本文选取两河口站 (lianghekou) 的 power_output 作为预测目标。

重要声明：该数据由程序按季节、降水滞后与简化水力学关系生成，不代表任何真实电站运行记录；结论仅用于方法对比与流程验证。

1.3.2 2.2 输入特征与预测任务

项目	设定
输入变量	太阳辐照度、风速、气温、降水、湿度、历史出力（共 6 维）
编码器输入长度 L_{enc}	168 h（7 d）
Informer 解码器标签长度 L_{label}	48 h
预测长度 L_{pred}	24 h
标准化	训练段 Z-score，验证/测试仅变换
样本划分	按时间先后 70% / 15% / 15%

目标函数为标准化空间上的均方误差 (MSE)；评价在反标准化后计算 MAE、RMSE、MAPE (MW 与%)。

1.4 3 方法

1.4.1 3.1 LSTM 基线模型

采用双层 LSTM（隐层维度 128，batch_first=True），取末时刻隐状态经两层全连接映射为未来 24 h 出力向量。该结构代表水电预测文献中常见的直接多步 (Direct Multi-step) 深度基线，参数量约 0.21 M。

1.4.2 3.2 Informer 模型

依据 Zhou et al. (2021) 的编码器—解码器范式实现：

- **编码器**：数据嵌入（线性 + 正弦位置编码）+ 2 层自注意力编码层 + 卷积蒸馏；
- **解码器**：1 层带掩码自注意力与交叉注意力的解码层；
- **输出**：解码序列末 L_{pred} 步经线性投影得到出力预测。

本实现中序列长度 $L = 168$ 相对适中，编码器采用**标准多头自注意力**以保证数值稳定；嵌入维度 64、注意力头数 4、前馈维度 256。解码器输入由**已知标签段**（48 h）与占位零填充的未来段构成。参数量约 **0.18 M**。

1.4.3 3.3 训练策略

- 优化器：AdamW ($lr = 10^{-4}$, weight decay 10^{-5})
- 学习率：验证损失平台期 ReduceLROnPlateau (factor=0.5, patience=3)
- Batch size: 128; Epoch: 20; 梯度裁剪: 1.0
- 硬件：NVIDIA RTX 5070 Ti Laptop GPU (CUDA)

1.5 4 实验结果

1.5.1 4.1 测试集整体指标

表 1 给出测试集上的点预测指标（6578 个滚动样本 $\times$ 24 步）。

模型	MAE (MW)	RMSE (MW)	MAPE (%)	参数量	训练耗时 (s)
LSTM	30.36	39.09	10.44	211 544	68.1
Informer	30.49	39.15	10.20	180 289	137.7

由表 1 可见：在本合成数据与统一超参下，**LSTM 的 MAE/RMSE 略优于 Informer**（相对 MAE 约 0.4%），Informer 在 MAPE 上略优；二者差异处于同一量级，尚不足以支持“**Informer 全面优于 LSTM**”的结论。

1.5.2 4.2 训练过程

两种模型验证损失均在约 10 个 epoch 后趋于平稳（见图 Fig1-b）。Informer 单 epoch 计算开销更高，总训练时间约为 LSTM 的 2.0 倍，与注意力及解码器结构一致。

1.5.3 4.3 预测片段与分步长误差

图 Fig1-c 展示典型 24 h 预测曲线：两模型均能跟踪日周期形态，峰值时段存在可辨偏差。图 Fig3 给出各提前步（1-24 h）的平均绝对误差；远期步长误差略有上升，符合短期预测一般规律。

1.5.4 4.4 误差分布

图 Fig2 显示两模型误差分布近似零均值、左偏轻微厚尾，未发现系统性整体高估或低估。

1.6 5 讨论

1.6.1 5.1 核心结果的含义

本研究的核心发现是：在同一合成数据集与训练协议下，Informer 并未在点预测误差上超越 LSTM——MAE/RMSE 略逊（约 0.4% 相对量级），MAPE 略优（10.20% 对 10.44%）。这表明，对于强周期、相对平滑的预演序列，增加编码器—解码器与交叉注意力带来的表达优势，不足以抵消结构复杂度与训练开销（Informer 训练耗时约为 LSTM 的 2 倍）。该结果与水文混合深度学习综述的结论一致：模型优势高度依赖输入构造、超参与是否引入分解/混合模块 [5,6]，不能由注意力机制单独保证。

从证据链看，Fig1-c 与 Fig3 显示两模型均能跟踪日周期形态，误差主要集中在峰段与转折段；Fig2 表明误差近似零均值，无系统性偏置。因而本文提供的价值更在于可审计的负结果（negative result）：在资源受限的学生工作站环境下，优先复现 LSTM 基线再尝试 Informer，可能是更稳妥的技术路线。

1.6.2 5.2 与已有工作的关系

Informer 原论文在电力、气象等 LSTF 基准上报告了对 Transformer 的改进 [1]；水电领域已有将 LSTM 与 Transformer 级联的工作 [8]，以及面向水电发电演化的深度生成框

架 DeepHydro[7]。本文与之的区别在于：（1）聚焦单站短期出力而非省域月度电量；（2）强调双模型对照而非单一最优模型；（3）显式报告分步长误差与训练成本。径流预测方向的混合深度学习综述 [5] 与 DL 水文预报综述 [6] 支持本文对「应做系统基线与消融」的论述，但不直接支持「Informer 必优于 LSTM」的推断。

1.6.3 5.3 局限与边界

第一，数据为合成：虽含季节、降水滞后与简化水力响应，但缺少机组组合、检修、泄洪指令与测量噪声，模型排序在真实 SCADA 上可能改变。第二，Informer 实现为稳定简化版（标准注意力、不完整 ProbSparse），与 AAAI 2021 原文存在差距 [1]。第三，未纳入持久性预测、线性模型、PatchTST 等对照 [3]，也未做概率预测与区间校准。第四，仅单站两河口，未建模梯级水力时滞与多站耦合 [10]。

1.6.4 5.4 向工程与大创的迁移路径

若将本框架用于安康或雅砻江脱敏数据，建议按以下顺序推进：（1）以 SCADA 实测替换合成序列，保留相同划分协议；（2）增加持久性预测与 Transformer-LSTM 混合基线 [8]；（3）对 Informer 做 L_{label} 、 d_{model} 与 ProbSparse 的敏感性分析；（4）引入分位数损失或共形预测，服务备用容量评估 [9]；（5）按丰枯、检修期分层报告指标。上述步骤完成后，方可讨论是否将 Informer 作为生产侧主模型。

1.6.5 5.5 AI 辅助开发说明

代码实现、文献整理、作图与文稿结构在生成式 AI 助手辅助下完成；正式投稿前须在导师指导下复核实验、引用与学校 AI 使用规定。引用条目与 DOI 见 manuscript/文献与引用说明.md 与 references.ris。

1.7 6 结论

本文在雅砻江流域合成数据上完成了 Informer 与 LSTM 的短期水电出力预测对比。在统一划分与评价下，LSTM 在 MAE/RMSE 上略优，Informer 在 MAPE 上略优，差异较小；Informer 计算成本更高。研究验证了对比实验流水线，并指出向真实数据与大创课题深化时须加强基线、调参与不确定性量化。

1.8 参考文献

- [1] Zhou H, Zhang S, Peng J, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(12): 11106-11115. <https://doi.org/10.1609/aaai.v35i12.17325>
- [2] Hochreiter S, Schmidhuber J. Long short-term memory[J]. *Neural Computation*, 1997, 9(8): 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- [3] Nie Y, Nguyen N H, Sinthong P, et al. A time series is worth 64 words: Long-term forecasting with transformers[J]. *arXiv:2211.14730*, 2022. <https://doi.org/10.48550/arXiv.2211.14730>
- [4] 张勇军, 刘明波, 林建熙. 水风光互补发电系统优化调度研究进展 [J]. *中国电机工程学报*, 2021, 41(10): 3456-3468.
- [5] Nga K W, Huang Y F, Koo C H, et al. A review of hybrid deep learning applications for streamflow forecasting[J]. *Journal of Hydrology*, 2023, 625: 130141. <https://doi.org/10.1016/j.jhydrol.2023.130141>
- [6] Huang Y F, Koo C H, et al. A comprehensive review of methods for hydrological forecasting based on deep learning[J]. *Water*, 2024, 16(10): 1407. <https://doi.org/10.3390/w16101407>
- [7] Zhou F, Li L, Zhang K, et al. Forecasting the evolution of hydropower generation[C]//Proceedings of KDD, 2020. <https://doi.org/10.1145/3394486.3403337>
- [8] Li Y, et al. Research on medium- and long-term hydropower generation forecasting method based on LSTM and Transformer[J]. *Energies*, 2024, 17(22): 5707. <https://doi.org/10.3390/en17225707>
- [9] Slater L J, Villarini G, et al. Hybrid forecasting: blending climate predictions with AI models[J]. *Hydrology and Earth System Sciences*, 2023, 27: 1865-1889. <https://doi.org/10.5194/hess-27-1865-2023>
- [10] Cai Z, Zhang G, et al. Method for LSTM-based cascade hydropower plant scheduling[C]//CCDC, 2021. <https://doi.org/10.1109/CCDC52312.2021.9602858>
- [11] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. *Nature*, 2015, 521: 436-444. <https://doi.org/10.1038/nature14539>
-

1.9 附录 A：复现命令

```
cd d:\agent\雅砻江 Informer_LSTM 对比研究
python train_compare.py
python plot_nature_figures.py
```

1.10 附录 B：图件清单

图号	文件	内容
Fig1	figures/Fig1_LSTM_Informer_comparison	四宫格总览
Fig2	figures/Fig2_error_distribution	误差直方图
Fig3	figures/Fig3_horizon_MAE	分步长 MAE

稿件版本：2026-05-11；指标来自 *results/metrics.json* 实测。

1.11 图件

雅砻江两河口站短期水电出力: Informer 与 LSTM 对比 (合成数据预演)




图 1: 图 1 LSTM 与 Informer 对比总览




图 2: 图 2 预测误差分布




图 3: 图 3 分提前步长 MAE